

Teori Generative Adversarial Network

Ryan Fadhilah Faizal Hakim¹

¹Sains Data, Fakultas Sains dan Teknologi, IKOPIN University

1 Pendahuluan

Generative Adversarial Network (GAN) adalah kerangka kerja *deep learning* generatif yang bertujuan mempelajari distribusi data sehingga model dapat menghasilkan sampel baru yang menyerupai data asli. GAN terdiri atas dua jaringan saraf yang dilatih secara adversarial, yaitu *generator* dan *discriminator*. Generator berusaha menghasilkan data palsu yang tampak realistis, sedangkan discriminator berusaha membedakan data asli dari data palsu.

Secara intuitif, GAN dapat dipandang sebagai permainan dua pemain. Generator bertindak sebagai pemalsu data, sedangkan discriminator bertindak sebagai pemeriksa keaslian data. Selama pelatihan, generator semakin baik dalam menghasilkan sampel, dan discriminator semakin baik dalam mendeteksi perbedaan antara sampel asli dan sampel buatan. Keseimbangan ideal terjadi ketika sampel generator tidak dapat lagi dibedakan dari data asli.

GAN banyak digunakan untuk sintesis citra, super-resolution, image-to-image translation, text-to-image generation, augmentasi data, inpainting, domain adaptation, generasi video, dan pemodelan distribusi kompleks. Kekuatan utama GAN adalah kemampuannya menghasilkan sampel tajam dan realistis, terutama pada domain citra.

2 Model Generatif

Model generatif bertujuan mempelajari distribusi data $p_{data}(\mathbf{x})$. Jika data pelatihan adalah

$$\mathcal{D} = \{\mathbf{x}^{(i)}\}_{i=1}^N, \quad \mathbf{x}^{(i)} \sim p_{data}(\mathbf{x}), \quad (1)$$

maka tujuan model generatif adalah membangun distribusi model $p_g(\mathbf{x})$ yang mendekati $p_{data}(\mathbf{x})$.

Secara umum, model generatif dapat digunakan untuk mengambil sampel baru

$$\tilde{\mathbf{x}} \sim p_g(\mathbf{x}), \quad (2)$$

dengan harapan bahwa $\tilde{\mathbf{x}}$ terlihat seperti berasal dari distribusi data asli.

Pada GAN, distribusi p_g tidak didefinisikan secara eksplisit. Sebaliknya, GAN mendefinisikan proses transformasi dari variabel laten $\mathbf{z}$ menjadi data sintetik:

$$\mathbf{z} \sim p_z(\mathbf{z}), \quad \tilde{\mathbf{x}} = G_\theta(\mathbf{z}). \quad (3)$$

Distribusi p_g adalah distribusi implisit yang dihasilkan oleh transformasi G_θ terhadap distribusi laten p_z .

3 Komponen Utama GAN

GAN memiliki dua komponen utama:

1. **Generator** G_θ : jaringan saraf yang memetakan noise laten $\mathbf{z}$ menjadi sampel palsu $\tilde{\mathbf{x}}$.
2. **Discriminator** D_ϕ : jaringan saraf yang menghasilkan probabilitas bahwa suatu sampel berasal dari data asli.

Generator ditulis sebagai

$$G_\theta : \mathbb{R}^{d_z} \rightarrow \mathbb{R}^{d_x}, \quad (4)$$

dengan θ adalah parameter generator. Input generator adalah noise laten

$$\mathbf{z} \sim p_z(\mathbf{z}), \quad (5)$$

misalnya distribusi normal standar

$$\mathbf{z} \sim \mathcal{N}(\mathbf{0}, \mathbf{I}) \quad (6)$$

atau distribusi uniform

$$\mathbf{z} \sim U(-1, 1)^{d_z}. \quad (7)$$

Discriminator ditulis sebagai

$$D_\phi : \mathbb{R}^{d_x} \rightarrow (0, 1), \quad (8)$$

dengan $D_\phi(\mathbf{x})$ merepresentasikan probabilitas bahwa $\mathbf{x}$ adalah data asli. Idealnya,

$$D_\phi(\mathbf{x}) \approx 1 \quad \text{untuk data asli}, \quad (9)$$

dan

$$D_\phi(G_\theta(\mathbf{z})) \approx 0 \quad \text{untuk data palsu}. \quad (10)$$

4 Fungsi Objektif Minimax

Formulasi dasar GAN adalah permainan minimax antara generator dan discriminator. Objektifnya adalah

$$\min_G \max_D V(D, G) = \mathbb{E}_{\mathbf{x} \sim p_{data}(\mathbf{x})} [\log D(\mathbf{x})] + \mathbb{E}_{\mathbf{z} \sim p_z(\mathbf{z})} [\log(1 - D(G(\mathbf{z})))] . \quad (11)$$

Discriminator berusaha memaksimalkan fungsi objektif tersebut. Term pertama mendorong $D(\mathbf{x})$ mendekati 1 untuk data asli. Term kedua mendorong $D(G(\mathbf{z}))$ mendekati 0 untuk data palsu. Sebaliknya, generator berusaha meminimalkan term kedua agar $D(G(\mathbf{z}))$ mendekati 1, yaitu membuat discriminator tertipu.

Dalam praktik, loss discriminator sering ditulis sebagai minimisasi negatif dari objektif discriminator:

$$\mathcal{L}_D = -\mathbb{E}_{\mathbf{x} \sim p_{data}} [\log D(\mathbf{x})] - \mathbb{E}_{\mathbf{z} \sim p_z} [\log(1 - D(G(\mathbf{z})))] \quad (12)$$

Loss generator versi minimax adalah

$$\mathcal{L}_G^{\text{minimax}} = \mathbb{E}_{\mathbf{z} \sim p_z} [\log(1 - D(G(\mathbf{z})))] \quad (13)$$

Namun, loss ini dapat menghasilkan gradien kecil ketika discriminator terlalu kuat. Oleh karena itu, sering digunakan *non-saturating generator loss*:

$$\mathcal{L}_G^{\text{NS}} = -\mathbb{E}_{\mathbf{z} \sim p_z} [\log D(G(\mathbf{z}))] \quad (14)$$

Loss non-saturating memiliki tujuan yang sama, yaitu membuat $D(G(\mathbf{z}))$ besar, tetapi memberikan gradien yang lebih kuat pada awal pelatihan.

5 Discriminator Optimal

Untuk generator tetap G , discriminator optimal dapat diturunkan secara analitis. Fungsi objektif dapat ditulis sebagai integral:

$$V(D, G) = \int p_{data}(\mathbf{x}) \log D(\mathbf{x}) d\mathbf{x} + \int p_g(\mathbf{x}) \log(1 - D(\mathbf{x})) d\mathbf{x} \quad (15)$$

Untuk setiap $\mathbf{x}$, kita memaksimalkan fungsi

$$f(D) = p_{data}(\mathbf{x}) \log D(\mathbf{x}) + p_g(\mathbf{x}) \log(1 - D(\mathbf{x})) \quad (16)$$

Turunan terhadap $D(\mathbf{x})$ adalah

$$\frac{\partial f}{\partial D} = \frac{p_{data}(\mathbf{x})}{D(\mathbf{x})} - \frac{p_g(\mathbf{x})}{1 - D(\mathbf{x})} \quad (17)$$

Dengan menyamakan turunan ke nol, diperoleh

$$D^*(\mathbf{x}) = \frac{p_{data}(\mathbf{x})}{p_{data}(\mathbf{x}) + p_g(\mathbf{x})} \quad (18)$$

Persamaan ini menunjukkan bahwa discriminator optimal membandingkan densitas data asli dan densitas generator.

Jika $p_g(\mathbf{x}) = p_{data}(\mathbf{x})$, maka

$$D^*(\mathbf{x}) = \frac{1}{2} \quad (19)$$

Artinya, discriminator tidak dapat membedakan data asli dan data palsu.

6 Hubungan dengan Jensen-Shannon Divergence

Dengan memasukkan discriminator optimal pada Persamaan (18) ke objektif GAN, diperoleh

$$V(D^*, G) = -\log 4 + 2 \text{JSD}(p_{data} \| p_g), \quad (20)$$

dengan JSD adalah *Jensen-Shannon Divergence*. Jensen-Shannon Divergence didefinisikan sebagai

$$\text{JSD}(P \| Q) = \frac{1}{2} \text{KL}(P \| M) + \frac{1}{2} \text{KL}(Q \| M), \quad (21)$$

dengan

$$M = \frac{1}{2}(P + Q). \quad (22)$$

KL divergence sendiri didefinisikan sebagai

$$\text{KL}(P \| Q) = \int p(\mathbf{x}) \log \frac{p(\mathbf{x})}{q(\mathbf{x})} d\mathbf{x}. \quad (23)$$

Karena $\text{JSD}(p_{data} \| p_g) \geq 0$, nilai minimum dicapai ketika

$$p_g = p_{data}. \quad (24)$$

Pada titik ini,

$$V(D^*, G) = -\log 4. \quad (25)$$

7 Proses Pelatihan GAN

Pelatihan GAN dilakukan secara bergantian antara discriminator dan generator. Untuk setiap iterasi, biasanya dilakukan beberapa langkah pembaruan discriminator, lalu satu langkah pembaruan generator.

Untuk mini-batch data asli $\{\mathbf{x}^{(i)}\}_{i=1}^B$ dan noise $\{\mathbf{z}^{(i)}\}_{i=1}^B$, loss discriminator empiris adalah

$$\hat{\mathcal{L}}_D = -\frac{1}{B} \sum_{i=1}^B \log D_\phi(\mathbf{x}^{(i)}) - \frac{1}{B} \sum_{i=1}^B \log \left(1 - D_\phi(G_\theta(\mathbf{z}^{(i)})) \right). \quad (26)$$

Pembaruan parameter discriminator adalah

$$\phi \leftarrow \phi - \eta_D \nabla_\phi \hat{\mathcal{L}}_D. \quad (27)$$

Untuk generator non-saturating, loss empirisnya adalah

$$\hat{\mathcal{L}}_G = -\frac{1}{B} \sum_{i=1}^B \log D_\phi(G_\theta(\mathbf{z}^{(i)})). \quad (28)$$

Pembaruan parameter generator adalah

$$\theta \leftarrow \theta - \eta_G \nabla_\theta \hat{\mathcal{L}}_G. \quad (29)$$

Gradien generator dihitung melalui komposisi $D_\phi(G_\theta(\mathbf{z}))$. Dengan aturan rantai,

$$\nabla_\theta \mathcal{L}_G = \frac{\partial \mathcal{L}_G}{\partial D} \frac{\partial D_\phi(\tilde{\mathbf{x}})}{\partial \tilde{\mathbf{x}}} \frac{\partial G_\theta(\mathbf{z})}{\partial \theta}, \quad (30)$$

dengan $\tilde{\mathbf{x}} = G_\theta(\mathbf{z})$. Parameter discriminator ϕ tidak diperbarui saat menghitung langkah generator, tetapi gradien tetap mengalir melewati discriminator menuju generator.

8 Interpretasi Game-Theoretic

GAN adalah permainan dua pemain dengan tujuan berlawanan. Discriminator memaksimalkan kemampuan klasifikasi, sedangkan generator meminimalkan kemampuan discriminator membedakan sampel palsu. Secara formal, GAN mencari titik ekuilibrium Nash:

$$V(D^*, G) \leq V(D^*, G^*) \leq V(D, G^*) \quad (31)$$

untuk setiap D dan G . Pada ekuilibrium ideal,

$$p_g = p_{data}, \quad D^*(\mathbf{x}) = \frac{1}{2}. \quad (32)$$

Namun, dalam praktik, pelatihan GAN tidak selalu mencapai ekuilibrium karena optimisasi dilakukan pada jaringan nonlinier berdimensi tinggi.

9 Masalah Utama dalam Pelatihan GAN

9.1 Mode Collapse

Mode collapse terjadi ketika generator hanya menghasilkan sedikit variasi sampel meskipun data asli memiliki banyak mode. Secara matematis, generator gagal merepresentasikan seluruh distribusi p_{data} dan hanya mencakup sebagian mode:

$$\text{supp}(p_g) \subsetneq \text{supp}(p_{data}). \quad (33)$$

Akibatnya, sampel terlihat realistis tetapi kurang beragam.

9.2 Vanishing Gradient

Jika discriminator terlalu kuat, maka $D(G(\mathbf{z})) \approx 0$. Untuk loss minimax,

$$\mathcal{L}_G^{\text{minimax}} = \log(1 - D(G(\mathbf{z}))), \quad (34)$$

gradien terhadap generator dapat menjadi sangat kecil. Inilah alasan loss non-saturating lebih sering digunakan.

9.3 Instabilitas Pelatihan

GAN melibatkan optimisasi dua objektif yang saling berkompetisi. Perubahan generator mengubah distribusi sampel palsu, sehingga target discriminator terus berubah. Sebaliknya, perubahan discriminator mengubah sinyal gradien generator. Hal ini dapat menyebabkan osilasi, divergensi, atau konvergensi yang tidak stabil.

10 Teknik Stabilisasi GAN

Beberapa teknik yang umum digunakan untuk menstabilkan pelatihan GAN adalah:

1. **Feature matching:** generator dilatih agar statistik fitur internal discriminator pada data palsu mendekati data asli.
2. **Label smoothing:** label asli tidak diberi nilai 1 secara penuh, tetapi misalnya 0.9.
3. **Instance noise:** noise kecil ditambahkan pada input discriminator.
4. **Spectral normalization:** membatasi Lipschitz constant discriminator.
5. **Gradient penalty:** menambahkan penalti terhadap norma gradien discriminator.
6. **Two Time-Scale Update Rule:** menggunakan learning rate berbeda untuk generator dan discriminator.

Pada label smoothing satu sisi, target data asli dapat diubah dari 1 menjadi α , dengan

$$0.8 \leq \alpha < 1. \quad (35)$$

Hal ini mencegah discriminator menjadi terlalu percaya diri.

11 Wasserstein GAN

Wasserstein GAN (WGAN) dikembangkan untuk mengatasi kelemahan GAN standar yang berkaitan dengan Jensen-Shannon divergence. WGAN menggunakan Wasserstein-1 distance atau Earth Mover's Distance:

$$W(p_{data}, p_g) = \inf_{\gamma \in \Pi(p_{data}, p_g)} \mathbb{E}_{(\mathbf{x}, \mathbf{y}) \sim \gamma} [\|\mathbf{x} - \mathbf{y}\|], \quad (36)$$

dengan $\Pi(p_{data}, p_g)$ adalah himpunan semua distribusi gabungan dengan marginal p_{data} dan p_g .

Berdasarkan dualitas Kantorovich-Rubinstein,

$$W(p_{data}, p_g) = \sup_{\|f\|_L \leq 1} \mathbb{E}_{\mathbf{x} \sim p_{data}} [f(\mathbf{x})] - \mathbb{E}_{\mathbf{z} \sim p_z} [f(G(\mathbf{z}))], \quad (37)$$

di mana f harus bersifat 1-Lipschitz. Dalam WGAN, discriminator diganti dengan *critic* D yang menghasilkan skor real-valued, bukan probabilitas.

Loss critic WGAN dapat ditulis sebagai

$$\mathcal{L}_D^{\text{WGAN}} = -\mathbb{E}_{\mathbf{x} \sim p_{data}}[D(\mathbf{x})] + \mathbb{E}_{\mathbf{z} \sim p_z}[D(G(\mathbf{z}))], \quad (38)$$

sedangkan loss generator adalah

$$\mathcal{L}_G^{\text{WGAN}} = -\mathbb{E}_{\mathbf{z} \sim p_z}[D(G(\mathbf{z}))]. \quad (39)$$

12 WGAN dengan Gradient Penalty

Untuk memenuhi kendala 1-Lipschitz, WGAN awal menggunakan weight clipping. Namun, teknik ini dapat membatasi kapasitas critic. Alternatif yang lebih stabil adalah gradient penalty. Loss WGAN-GP adalah

$$\mathcal{L}_D^{\text{WGAN-GP}} = \mathbb{E}_{\tilde{\mathbf{x}} \sim p_g}[D(\tilde{\mathbf{x}})] - \mathbb{E}_{\mathbf{x} \sim p_{data}}[D(\mathbf{x})] + \lambda \mathbb{E}_{\hat{\mathbf{x}} \sim p_{\hat{\mathbf{x}}}}[(\|\nabla_{\hat{\mathbf{x}}} D(\hat{\mathbf{x}})\|_2 - 1)^2]. \quad (40)$$

Sampel interpolasi didefinisikan sebagai

$$\hat{\mathbf{x}} = \epsilon \mathbf{x} + (1 - \epsilon) \tilde{\mathbf{x}}, \quad \epsilon \sim U(0, 1). \quad (41)$$

Penalti ini mendorong norma gradien critic terhadap input mendekati satu.

13 Conditional GAN

Conditional GAN (cGAN) memungkinkan generator menghasilkan sampel berdasarkan kondisi tertentu, misalnya label kelas, teks, atau citra lain. Generator dan discriminator menerima kondisi $\mathbf{y}$:

$$\tilde{\mathbf{x}} = G(\mathbf{z}, \mathbf{y}), \quad (42)$$

dan

$$D(\mathbf{x}, \mathbf{y}) \in (0, 1). \quad (43)$$

Objektif cGAN adalah

$$\min_G \max_D V(D, G) = \mathbb{E}_{\mathbf{x}, \mathbf{y} \sim p_{data}}[\log D(\mathbf{x}, \mathbf{y})] + \mathbb{E}_{\mathbf{z} \sim p_z, \mathbf{y} \sim p_y}[\log(1 - D(G(\mathbf{z}, \mathbf{y}), \mathbf{y}))]. \quad (44)$$

Dengan kondisi, generator dapat diarahkan untuk menghasilkan sampel dari kelas atau domain tertentu.

14 Deep Convolutional GAN

Deep Convolutional GAN (DCGAN) adalah varian GAN yang menggunakan convolutional neural network untuk generator dan discriminator, terutama pada data citra. Generator biasanya menggunakan transposed convolution atau upsampling untuk meningkatkan resolusi spasial, sedangkan discriminator menggunakan convolution untuk mengekstraksi fitur citra.

Jika generator menghasilkan feature map bertahap,

$$\mathbf{h}^{(0)} = \mathbf{z}, \quad \mathbf{h}^{(\ell)} = \phi(\text{ConvTranspose}^{(\ell)}(\mathbf{h}^{(\ell-1)})), \quad (45)$$

maka output akhir dapat ditulis sebagai

$$\tilde{\mathbf{x}} = \tanh(\text{ConvTranspose}^{(L)}(\mathbf{h}^{(L-1)})). \quad (46)$$

Fungsi tanh sering digunakan jika piksel gambar dinormalisasi ke rentang $[-1, 1]$.

15 Least Squares GAN

Least Squares GAN (LSGAN) mengganti loss binary cross-entropy dengan least squares loss. Loss discriminator adalah

$$\mathcal{L}_D^{\text{LSGAN}} = \frac{1}{2} \mathbb{E}_{\mathbf{x} \sim p_{\text{data}}} [(D(\mathbf{x}) - b)^2] + \frac{1}{2} \mathbb{E}_{\mathbf{z} \sim p_z} [(D(G(\mathbf{z})) - a)^2], \quad (47)$$

sedangkan loss generator adalah

$$\mathcal{L}_G^{\text{LSGAN}} = \frac{1}{2} \mathbb{E}_{\mathbf{z} \sim p_z} [(D(G(\mathbf{z})) - c)^2]. \quad (48)$$

Biasanya $a = 0$, $b = 1$, dan $c = 1$. LSGAN dapat menghasilkan gradien yang lebih stabil dibanding GAN standar dalam beberapa kasus.

16 CycleGAN

CycleGAN digunakan untuk *image-to-image translation* tanpa pasangan data. Misalkan terdapat dua domain X dan Y . CycleGAN mempelajari dua generator:

$$G : X \rightarrow Y, \quad F : Y \rightarrow X, \quad (49)$$

serta dua discriminator D_X dan D_Y . Selain adversarial loss, CycleGAN menggunakan cycle-consistency loss:

$$\mathcal{L}_{\text{cyc}}(G, F) = \mathbb{E}_{\mathbf{x} \sim p_X} [\|F(G(\mathbf{x})) - \mathbf{x}\|_1] + \mathbb{E}_{\mathbf{y} \sim p_Y} [\|G(F(\mathbf{y})) - \mathbf{y}\|_1]. \quad (50)$$

Loss totalnya adalah

$$\mathcal{L}(G, F, D_X, D_Y) = \mathcal{L}_{\text{GAN}}(G, D_Y, X, Y) + \mathcal{L}_{\text{GAN}}(F, D_X, Y, X) + \lambda \mathcal{L}_{\text{cyc}}(G, F). \quad (51)$$

Cycle-consistency memastikan bahwa hasil translasi dapat dikembalikan ke domain asal.

17 Evaluasi GAN

Evaluasi GAN sulit karena tidak cukup hanya melihat loss generator dan discriminator. Beberapa metrik umum adalah Inception Score (IS) dan Fréchet Inception Distance (FID).

Inception Score didefinisikan sebagai

$$\text{IS} = \exp \left(\mathbb{E}_{\mathbf{x} \sim p_g} [\text{KL}(p(y|\mathbf{x}) \| p(y))] \right). \quad (52)$$

Skor tinggi menunjukkan bahwa gambar individual mudah diklasifikasikan dan keseluruhan sampel memiliki keragaman kelas.

FID membandingkan distribusi fitur data asli dan data palsu. Jika fitur asli memiliki mean dan kovariansi $(\boldsymbol{\mu}_r, \boldsymbol{\Sigma}_r)$, sedangkan fitur palsu memiliki $(\boldsymbol{\mu}_g, \boldsymbol{\Sigma}_g)$, maka

$$\text{FID} = \|\boldsymbol{\mu}_r - \boldsymbol{\mu}_g\|_2^2 + \text{Tr} \left(\boldsymbol{\Sigma}_r + \boldsymbol{\Sigma}_g - 2(\boldsymbol{\Sigma}_r \boldsymbol{\Sigma}_g)^{1/2} \right). \quad (53)$$

FID yang lebih rendah menunjukkan distribusi sampel generator lebih dekat dengan data asli.

18 Contoh Perhitungan Sederhana

Misalkan discriminator menghasilkan $D(\mathbf{x}) = 0.9$ untuk data asli dan $D(G(\mathbf{z})) = 0.2$ untuk data palsu. Loss discriminator untuk satu sampel asli dan satu sampel palsu adalah

$$\mathcal{L}_D = -\log(0.9) - \log(1 - 0.2). \quad (54)$$

Dengan pendekatan numerik,

$$\mathcal{L}_D \approx 0.105 + 0.223 = 0.328. \quad (55)$$

Loss generator non-saturating adalah

$$\mathcal{L}_G^{\text{NS}} = -\log(0.2) \approx 1.609. \quad (56)$$

Nilai ini cukup besar, menunjukkan bahwa generator masih gagal menipu discriminator.

Jika setelah pelatihan $D(G(\mathbf{z})) = 0.7$, maka

$$\mathcal{L}_G^{\text{NS}} = -\log(0.7) \approx 0.357, \quad (57)$$

yang menunjukkan generator telah membaik.

19 Kelebihan dan Keterbatasan GAN

Kelebihan GAN meliputi:

- mampu menghasilkan sampel realistis dan tajam,
- tidak membutuhkan likelihood eksplisit,
- fleksibel untuk berbagai jenis data dan kondisi,
- dapat digunakan untuk augmentasi dan translasi domain,
- mendukung pembelajaran distribusi data kompleks secara implisit.

Keterbatasan GAN meliputi:

- pelatihan sulit dan tidak stabil,
- rentan terhadap mode collapse,
- evaluasi kualitas dan keragaman sampel tidak sederhana,
- membutuhkan keseimbangan antara generator dan discriminator,
- dapat disalahgunakan untuk membuat konten sintetis yang menyesatkan.

20 Perbandingan GAN dengan Model Generatif Lain

Aspek	GAN	VAE	Autoregressive Model
Likelihood eksplisit	Tidak langsung	Ada lower bound	Ada
Kualitas sampel	Sering tajam	Lebih halus atau buram	Baik tetapi lambat
Kecepatan sampling	Cepat	Cepat	Lambat sekuensial
Stabilitas training	Sulit	Relatif stabil	Relatif stabil
Risiko mode collapse	Tinggi	Lebih rendah	Lebih rendah
Ide utama	Permainan adversarial	Variational inference	Faktorisasi probabilitas

21 Aplikasi GAN

Beberapa aplikasi GAN antara lain:

1. **Sintesis citra:** menghasilkan wajah, objek, atau pemandangan realistis.
2. **Super-resolution:** meningkatkan resolusi gambar rendah menjadi gambar resolusi tinggi.
3. **Image-to-image translation:** mengubah citra dari satu domain ke domain lain.
4. **Inpainting:** mengisi bagian gambar yang hilang atau rusak.

5. **Augmentasi data:** membuat data tambahan untuk pelatihan model lain.
6. **Domain adaptation:** membantu model bekerja pada domain berbeda.
7. **Generasi video:** menghasilkan atau memprediksi frame video.
8. **Data medis sintetis:** menghasilkan citra medis sintetis untuk riset dan pelatihan.

22 Aspek Etis

GAN memiliki potensi besar, tetapi juga menimbulkan risiko etis. Kemampuan menghasilkan citra, suara, atau video realistis dapat digunakan untuk membuat deepfake, disinformasi, atau pemalsuan identitas. Oleh karena itu, penggunaan GAN perlu memperhatikan transparansi, izin data, keamanan, dan deteksi konten sintetis.

Secara praktis, pengembangan GAN sebaiknya mempertimbangkan:

- penggunaan data yang sah dan etis,
- mitigasi bias pada data pelatihan,
- pelabelan konten sintetis,
- mekanisme deteksi penyalahgunaan,
- evaluasi dampak sosial dari sistem generatif.

23 Kesimpulan

Generative Adversarial Network adalah kerangka model generatif yang melatih generator dan discriminator dalam permainan adversarial. Generator mempelajari transformasi dari ruang laten ke ruang data, sedangkan discriminator memberikan sinyal pembelajaran dengan membedakan data asli dan data palsu. Formulasi dasar GAN adalah objektif minimax yang secara teoritis berkaitan dengan Jensen-Shannon divergence, dan solusi idealnya tercapai ketika distribusi generator sama dengan distribusi data asli.

Meskipun GAN dapat menghasilkan sampel yang sangat realistis, pelatihannya sering sulit karena mode collapse, vanishing gradient, dan instabilitas optimisasi. Berbagai varian seperti WGAN, WGAN-GP, cGAN, DCGAN, LSGAN, dan CycleGAN dikembangkan untuk meningkatkan stabilitas, kontrol, dan kemampuan aplikasi GAN. Dengan pemahaman matematis yang kuat, GAN dapat digunakan secara efektif dalam berbagai bidang, tetapi tetap perlu diterapkan secara bertanggung jawab karena potensi dampak etisnya.