

Teori Regularization dalam Deep Learning

Ryan Fadhilah Faizal Hakim¹

¹Sains Data, Fakultas Sains dan Teknologi, IKOPIN University

1 Pendahuluan

Regularization atau regularisasi adalah sekumpulan teknik dalam pembelajaran mesin dan deep learning yang bertujuan meningkatkan kemampuan generalisasi model. Generalisasi berarti kemampuan model untuk bekerja baik pada data baru yang tidak terlihat selama pelatihan. Dalam deep learning, regularisasi sangat penting karena jaringan saraf modern sering memiliki jutaan hingga miliaran parameter sehingga berpotensi mengalami *overfitting*.

Overfitting terjadi ketika model terlalu menyesuaikan diri terhadap data pelatihan, termasuk noise dan pola kebetulan, sehingga performanya buruk pada data validasi atau data uji. Regularisasi mengendalikan kompleksitas efektif model, membatasi parameter, menambahkan noise, memperbanyak variasi data, atau mengubah prosedur pelatihan agar model tidak hanya menghafal data latih.

Secara umum, regularisasi menambahkan preferensi atau batasan terhadap solusi model. Preferensi tersebut dapat berupa bobot kecil, representasi jarang, fungsi halus, invariansi terhadap transformasi, atau stabilitas terhadap gangguan kecil.

2 Notasi Dasar

Misalkan tersedia dataset pelatihan

$$\mathcal{D}_{train} = \{(\mathbf{x}^{(i)}, y^{(i)})\}_{i=1}^N, \quad (1)$$

dengan $\mathbf{x}^{(i)} \in \mathbb{R}^d$ adalah input dan $y^{(i)}$ adalah target. Model deep learning ditulis sebagai

$$\hat{y} = f_{\theta}(\mathbf{x}), \quad (2)$$

dengan θ adalah seluruh parameter model, misalnya bobot dan bias.

Fungsi risiko empiris tanpa regularisasi adalah

$$\hat{R}(\theta) = \frac{1}{N} \sum_{i=1}^N \mathcal{L}(f_{\theta}(\mathbf{x}^{(i)}), y^{(i)}), \quad (3)$$

dengan $\mathcal{L}$ adalah fungsi loss. Tujuan pelatihan biasa adalah

$$\theta^* = \arg \min_{\theta} \hat{R}(\theta). \quad (4)$$

Dengan regularisasi, objektif pelatihan menjadi

$$\theta^* = \arg \min_{\theta} \left[\hat{R}(\theta) + \lambda \Omega(\theta) \right], \quad (5)$$

dengan $\Omega(\theta)$ adalah penalti regularisasi dan $\lambda \geq 0$ adalah koefisien regularisasi.

3 Generalization Error

Risiko sebenarnya pada distribusi data populasi adalah

$$R(\theta) = \mathbb{E}_{(\mathbf{x}, y) \sim P_{data}} [\mathcal{L}(f_{\theta}(\mathbf{x}), y)]. \quad (6)$$

Karena distribusi populasi tidak diketahui, model dilatih menggunakan risiko empiris $\hat{R}(\theta)$. Gap generalisasi didefinisikan sebagai

$$G(\theta) = R(\theta) - \hat{R}(\theta). \quad (7)$$

Regularisasi bertujuan memperkecil risiko sebenarnya $R(\theta)$, bukan sekadar memperkecil loss pelatihan $\hat{R}(\theta)$.

Dalam praktik, performa generalisasi dipantau menggunakan data validasi:

$$\hat{R}_{val}(\theta) = \frac{1}{N_{val}} \sum_{i=1}^{N_{val}} \mathcal{L}(f_{\theta}(\mathbf{x}_{val}^{(i)}), y_{val}^{(i)}). \quad (8)$$

Jika loss training turun tetapi loss validasi naik, model kemungkinan mengalami overfitting.

4 Bias-Variance Tradeoff

Regularisasi dapat dijelaskan melalui bias-variance tradeoff. Untuk regresi, error ekspektasi dapat diuraikan sebagai

$$\mathbb{E} \left[(y - \hat{f}(\mathbf{x}))^2 \right] = \text{Bias}(\hat{f})^2 + \text{Var}(\hat{f}) + \sigma^2, \quad (9)$$

dengan σ^2 adalah noise irreducible. Model yang terlalu kompleks memiliki varians tinggi, sedangkan model yang terlalu sederhana memiliki bias tinggi.

Regularisasi biasanya meningkatkan bias sedikit, tetapi menurunkan varians secara signifikan. Jika penurunan varians lebih besar daripada kenaikan bias, performa pada data baru meningkat.

5 Regularisasi L2 dan Weight Decay

Regularisasi L2 menambahkan penalti kuadrat norma bobot:

$$\Omega_{L2}(\theta) = \|\theta\|_2^2 = \sum_j \theta_j^2. \quad (10)$$

Objektif regularisasi L2 adalah

$$\mathcal{J}(\theta) = \hat{R}(\theta) + \lambda \|\theta\|_2^2. \quad (11)$$

Gradiennya adalah

$$\nabla_{\theta} \mathcal{J}(\theta) = \nabla_{\theta} \hat{R}(\theta) + 2\lambda\theta. \quad (12)$$

Dengan gradient descent,

$$\theta_{t+1} = \theta_t - \eta \left(\nabla_{\theta} \hat{R}(\theta_t) + 2\lambda\theta_t \right). \quad (13)$$

Ini dapat ditulis sebagai

$$\theta_{t+1} = (1 - 2\eta\lambda)\theta_t - \eta \nabla_{\theta} \hat{R}(\theta_t). \quad (14)$$

Faktor $(1 - 2\eta\lambda)$ mengecilkan bobot pada setiap iterasi, sehingga L2 sering disebut *weight decay*.

Regularisasi L2 mendorong bobot kecil dan solusi yang lebih halus. Bobot yang terlalu besar sering menunjukkan model sangat sensitif terhadap input, sehingga berisiko overfitting.

6 Regularisasi L1

Regularisasi L1 menambahkan penalti jumlah nilai absolut parameter:

$$\Omega_{L1}(\theta) = \|\theta\|_1 = \sum_j |\theta_j|. \quad (15)$$

Objektifnya adalah

$$\mathcal{J}(\theta) = \hat{R}(\theta) + \lambda \|\theta\|_1. \quad (16)$$

Subgradien L1 adalah

$$\frac{\partial |\theta_j|}{\partial \theta_j} = \begin{cases} 1, & \theta_j > 0, \\ -1, & \theta_j < 0, \\ [-1, 1], & \theta_j = 0. \end{cases} \quad (17)$$

Regularisasi L1 cenderung menghasilkan parameter sparse, yaitu banyak parameter menjadi nol. Hal ini berguna untuk seleksi fitur dan model yang lebih ringkas.

7 Elastic Net

Elastic Net menggabungkan L1 dan L2:

$$\mathcal{J}(\theta) = \hat{R}(\theta) + \lambda_1 \|\theta\|_1 + \lambda_2 \|\theta\|_2^2. \quad (18)$$

L1 mendorong sparsity, sedangkan L2 menjaga bobot tetap kecil dan stabil. Kombinasi ini berguna ketika fitur saling berkorelasi dan model membutuhkan regularisasi kuat.

8 Dropout

Dropout adalah teknik regularisasi yang menonaktifkan sebagian neuron secara acak selama pelatihan. Misalkan aktivasi suatu lapisan adalah $\mathbf{h}$. Dropout membuat mask acak

$$m_j \sim \text{Bernoulli}(q), \quad (19)$$

dengan q adalah probabilitas neuron dipertahankan. Aktivasi setelah dropout adalah

$$\tilde{\mathbf{h}} = \frac{\mathbf{m} \odot \mathbf{h}}{q}. \quad (20)$$

Faktor $1/q$ digunakan pada *inverted dropout* agar ekspektasi aktivasi tetap sama:

$$\mathbb{E}[\tilde{h}_j] = h_j. \quad (21)$$

Dropout dapat dipandang sebagai pelatihan ensemble dari banyak subnetworks yang berbagi parameter. Pada saat inferensi, dropout dimatikan dan seluruh neuron digunakan.

9 DropConnect

DropConnect mirip dengan dropout, tetapi yang dinonaktifkan adalah bobot, bukan aktivasi. Jika suatu lapisan linear adalah

$$\mathbf{h} = \sigma(\mathbf{W}\mathbf{x} + \mathbf{b}), \quad (22)$$

DropConnect menggunakan mask pada bobot:

$$\tilde{\mathbf{W}} = \mathbf{M} \odot \mathbf{W}, \quad M_{ij} \sim \text{Bernoulli}(q). \quad (23)$$

Output menjadi

$$\mathbf{h} = \sigma(\tilde{\mathbf{W}}\mathbf{x} + \mathbf{b}). \quad (24)$$

Teknik ini menambahkan noise langsung pada koneksi parameter sehingga mengurangi ketergantungan pada bobot tertentu.

10 Data Augmentation

Data augmentation memperbesar variasi data pelatihan melalui transformasi yang mempertahankan label. Jika T adalah transformasi acak dari distribusi transformasi $\mathcal{T}$, maka sampel augmentasi adalah

$$\tilde{\mathbf{x}} = T(\mathbf{x}), \quad T \sim \mathcal{T}. \quad (25)$$

Objektif pelatihan dengan augmentasi adalah

$$\min_{\theta} \mathbb{E}_{(\mathbf{x}, y) \sim \mathcal{D}} \mathbb{E}_{T \sim \mathcal{T}} [\mathcal{L}(f_{\theta}(T(\mathbf{x})), y)]. \quad (26)$$

Pada citra, augmentasi dapat berupa crop, flip, rotasi, perubahan warna, blur, noise, dan cutout. Pada teks, augmentasi dapat berupa paraphrase, synonym replacement, back-translation, atau masking. Pada audio, augmentasi dapat berupa time shift, noise injection, pitch shift, dan time stretching.

11 Noise Injection

Noise injection menambahkan noise pada input, aktivasi, atau bobot. Pada input,

$$\tilde{\mathbf{x}} = \mathbf{x} + \boldsymbol{\epsilon}, \quad \boldsymbol{\epsilon} \sim \mathcal{N}(\mathbf{0}, \sigma^2 \mathbf{I}). \quad (27)$$

Objektifnya menjadi

$$\mathbb{E}_{\boldsymbol{\epsilon}} [\mathcal{L}(f_{\theta}(\mathbf{x} + \boldsymbol{\epsilon}), y)]. \quad (28)$$

Untuk noise kecil, pendekatan Taylor menunjukkan bahwa noise injection mendorong fungsi menjadi halus terhadap input. Jika model sangat berubah akibat noise kecil, loss rata-rata akan meningkat.

12 Early Stopping

Early stopping menghentikan pelatihan ketika performa validasi tidak membaik. Misalkan loss validasi pada epoch t adalah $\mathcal{L}_{val}^{(t)}$. Pelatihan dihentikan jika

$$\mathcal{L}_{val}^{(t)} > \min_{s < t} \mathcal{L}_{val}^{(s)} \quad (29)$$

selama sejumlah epoch tertentu yang disebut patience.

Early stopping merupakan regularisasi karena membatasi lamanya optimisasi. Pada banyak kasus, model mulai mempelajari pola umum pada awal pelatihan dan kemudian menghafal noise jika dilatih terlalu lama.

13 Batch Normalization sebagai Regularisasi

Batch normalization menormalkan aktivasi menggunakan statistik mini-batch. Untuk aktivasi $x_1, x_2, \dots, x_m$, dihitung

$$\mu_B = \frac{1}{m} \sum_{i=1}^m x_i, \quad (30)$$

$$\sigma_B^2 = \frac{1}{m} \sum_{i=1}^m (x_i - \mu_B)^2, \quad (31)$$

$$\hat{x}_i = \frac{x_i - \mu_B}{\sqrt{\sigma_B^2 + \epsilon}}, \quad (32)$$

$$y_i = \gamma \hat{x}_i + \beta. \quad (33)$$

Walaupun tujuan utama batch normalization adalah menstabilkan pelatihan, penggunaan statistik mini-batch juga menambahkan noise stokastik sehingga memiliki efek regularisasi.

14 Layer Normalization dan Regularisasi

Layer normalization menormalkan aktivasi dalam satu sampel, bukan antar sampel dalam mini-batch. Untuk vektor aktivasi $\mathbf{h} \in \mathbb{R}^d$,

$$\mu = \frac{1}{d} \sum_{j=1}^d h_j, \quad (34)$$

$$\sigma^2 = \frac{1}{d} \sum_{j=1}^d (h_j - \mu)^2, \quad (35)$$

$$\hat{h}_j = \frac{h_j - \mu}{\sqrt{\sigma^2 + \epsilon}}. \quad (36)$$

Layer normalization sangat umum pada Transformer. Efek regularisasinya tidak sekuat dropout, tetapi membantu stabilitas dan mencegah aktivasi menjadi terlalu besar.

15 Label Smoothing

Label smoothing mencegah model menjadi terlalu percaya diri. Pada klasifikasi K kelas, label one-hot biasanya

$$y_k = \begin{cases} 1, & k = c, \\ 0, & k \neq c. \end{cases} \quad (37)$$

Dengan label smoothing, target diubah menjadi

$$y_k^{LS} = \begin{cases} 1 - \epsilon, & k = c, \\ \frac{\epsilon}{K-1}, & k \neq c. \end{cases} \quad (38)$$

Loss cross-entropy menjadi

$$\mathcal{L}_{LS} = - \sum_{k=1}^K y_k^{LS} \log p_{\theta}(k|\mathbf{x}). \quad (39)$$

Label smoothing mengurangi overconfidence dan sering meningkatkan kalibrasi probabilitas.

16 Mixup

Mixup membuat sampel pelatihan baru dengan interpolasi linear antara dua sampel. Untuk dua sampel $(\mathbf{x}_i, y_i)$ dan $(\mathbf{x}_j, y_j)$,

$$\tilde{\mathbf{x}} = \lambda \mathbf{x}_i + (1 - \lambda) \mathbf{x}_j, \quad (40)$$

$$\tilde{y} = \lambda y_i + (1 - \lambda) y_j, \quad (41)$$

dengan

$$\lambda \sim \text{Beta}(\alpha, \alpha). \quad (42)$$

Model dilatih dengan loss

$$\mathcal{L} = \mathcal{L}(f_\theta(\tilde{\mathbf{x}}), \tilde{y}). \quad (43)$$

Mixup mendorong model berperilaku linear di antara sampel pelatihan dan mengurangi keputusan yang terlalu tajam.

17 Cutout dan CutMix

Cutout menghapus sebagian area input, terutama pada citra. Jika mask $\mathbf{M}$ bernilai 0 pada area yang dihapus dan 1 pada area lain, input baru adalah

$$\tilde{\mathbf{x}} = \mathbf{M} \odot \mathbf{x}. \quad (44)$$

CutMix mengganti sebagian area citra dengan area dari citra lain:

$$\tilde{\mathbf{x}} = \mathbf{M} \odot \mathbf{x}_i + (1 - \mathbf{M}) \odot \mathbf{x}_j. \quad (45)$$

Label juga dicampur berdasarkan proporsi area:

$$\tilde{y} = \lambda y_i + (1 - \lambda) y_j. \quad (46)$$

18 Weight Sharing

Weight sharing adalah bentuk regularisasi struktural. Pada CNN, filter yang sama digunakan di semua lokasi spasial. Jika kernel adalah $\mathbf{K}$, maka output konvolusi adalah

$$\mathbf{Y}[i, j] = \sum_{u, v} \mathbf{K}[u, v] \mathbf{X}[i + u, j + v]. \quad (47)$$

Karena parameter yang sama digunakan di banyak lokasi, jumlah parameter berkurang drastis. Hal ini membatasi kompleksitas model dan meningkatkan generalisasi.

19 Parameter Tying

Parameter tying mengikat beberapa parameter agar memiliki nilai yang sama. Pada autoencoder tertentu, bobot decoder dapat diikat dengan bobot encoder:

$$\mathbf{W}_d = \mathbf{W}_e^T. \quad (48)$$

Dengan demikian jumlah parameter berkurang dan model dipaksa mempelajari struktur yang lebih konsisten.

20 Max-Norm Regularization

Max-norm regularization membatasi norma bobot yang masuk ke suatu neuron:

$$\|\mathbf{w}_j\|_2 \leq c. \quad (49)$$

Setelah pembaruan gradient, bobot diproyeksikan kembali jika melebihi batas:

$$\mathbf{w}_j \leftarrow \mathbf{w}_j \frac{c}{\|\mathbf{w}_j\|_2} \quad \text{jika } \|\mathbf{w}_j\|_2 > c. \quad (50)$$

Teknik ini mencegah bobot menjadi terlalu besar dan sering digunakan bersama dropout.

21 Spectral Normalization

Spectral normalization membatasi norma spektral matriks bobot. Untuk matriks $\mathbf{W}$, norma spektral adalah singular value terbesar:

$$\sigma(\mathbf{W}) = \max_{\mathbf{h} \neq 0} \frac{\|\mathbf{W}\mathbf{h}\|_2}{\|\mathbf{h}\|_2}. \quad (51)$$

Bobot dinormalisasi menjadi

$$\bar{\mathbf{W}} = \frac{\mathbf{W}}{\sigma(\mathbf{W})}. \quad (52)$$

Spectral normalization membatasi Lipschitz constant lapisan dan sering digunakan pada GAN agar discriminator lebih stabil.

22 Gradient Clipping

Gradient clipping membatasi norma gradien untuk mencegah exploding gradient. Jika gradien adalah $\mathbf{g}$, maka clipping berdasarkan norma adalah

$$\mathbf{g} \leftarrow \begin{cases} \mathbf{g}, & \|\mathbf{g}\|_2 \leq c, \\ c \frac{\mathbf{g}}{\|\mathbf{g}\|_2}, & \|\mathbf{g}\|_2 > c. \end{cases} \quad (53)$$

Walaupun sering dianggap teknik stabilisasi, gradient clipping juga memiliki efek regularisasi karena membatasi perubahan parameter yang terlalu besar.

23 Adversarial Training

Adversarial training melatih model agar robust terhadap gangguan kecil yang dirancang untuk menipu model. Gangguan adversarial didefinisikan sebagai

$$\boldsymbol{\delta}^* = \arg \max_{\|\boldsymbol{\delta}\| \leq \epsilon} \mathcal{L}(f_{\theta}(\mathbf{x} + \boldsymbol{\delta}), y). \quad (54)$$

Objektif adversarial training adalah

$$\min_{\theta} \mathbb{E}_{(\mathbf{x}, y)} \left[\max_{\|\boldsymbol{\delta}\| \leq \epsilon} \mathcal{L}(f_{\theta}(\mathbf{x} + \boldsymbol{\delta}), y) \right]. \quad (55)$$

Metode FGSM menggunakan pendekatan

$$\boldsymbol{\delta} = \epsilon \text{sign}(\nabla_{\mathbf{x}} \mathcal{L}(f_{\theta}(\mathbf{x}), y)). \quad (56)$$

Adversarial training meningkatkan robustness, tetapi dapat meningkatkan biaya pelatihan.

24 Consistency Regularization

Consistency regularization mendorong model menghasilkan prediksi konsisten terhadap perturbasi input. Misalkan T_1 dan T_2 adalah dua augmentasi acak. Loss konsistensi dapat ditulis sebagai

$$\mathcal{L}_{cons} = \|f_{\theta}(T_1(\mathbf{x})) - f_{\theta}(T_2(\mathbf{x}))\|_2^2. \quad (57)$$

Objektif total adalah

$$\mathcal{J} = \mathcal{L}_{sup} + \lambda \mathcal{L}_{cons}. \quad (58)$$

Teknik ini banyak digunakan pada semi-supervised learning.

25 Knowledge Distillation sebagai Regularisasi

Knowledge distillation melatih model siswa agar meniru distribusi output model guru. Jika logit guru adalah $\mathbf{z}^T$ dan logit siswa adalah $\mathbf{z}^S$, probabilitas dengan temperature τ adalah

$$p_k^T = \frac{\exp(z_k^T / \tau)}{\sum_j \exp(z_j^T / \tau)}, \quad p_k^S = \frac{\exp(z_k^S / \tau)}{\sum_j \exp(z_j^S / \tau)}. \quad (59)$$

Loss distillation adalah

$$\mathcal{L}_{KD} = \tau^2 \text{KL}(\mathbf{p}^T \parallel \mathbf{p}^S). \quad (60)$$

Objektif total sering berupa kombinasi dengan cross-entropy label asli:

$$\mathcal{L} = \alpha \mathcal{L}_{CE} + (1 - \alpha) \mathcal{L}_{KD}. \quad (61)$$

Soft target dari guru berperan sebagai regularizer karena mengandung informasi relasi antar kelas.

26 Bayesian View of Regularization

Regularisasi dapat ditafsirkan sebagai prior Bayesian pada parameter. Posterior parameter adalah

$$p(\theta|\mathcal{D}) \propto p(\mathcal{D}|\theta)p(\theta). \quad (62)$$

Maximum a posteriori (MAP) estimation memaksimalkan

$$\log p(\theta|\mathcal{D}) = \log p(\mathcal{D}|\theta) + \log p(\theta) + C. \quad (63)$$

Jika prior parameter Gaussian,

$$p(\theta) \propto \exp\left(-\frac{\lambda}{2}\|\theta\|_2^2\right), \quad (64)$$

maka MAP ekuivalen dengan regularisasi L2. Jika prior Laplace,

$$p(\theta) \propto \exp(-\lambda\|\theta\|_1), \quad (65)$$

maka MAP ekuivalen dengan regularisasi L1.

27 Regularisasi pada Transformer

Pada Transformer, regularisasi umum meliputi dropout pada attention, dropout pada feed-forward layer, weight decay, label smoothing, dan data augmentation. Attention dropout menerapkan mask pada bobot attention:

$$\tilde{\mathbf{A}} = \frac{\mathbf{M} \odot \mathbf{A}}{q}, \quad M_{ij} \sim \text{Bernoulli}(q). \quad (66)$$

Output attention menjadi

$$\mathbf{H} = \tilde{\mathbf{A}}\mathbf{V}. \quad (67)$$

Pada model bahasa besar, weight decay dan dropout sering digunakan secara hati-hati karena model sangat besar dapat memiliki dinamika generalisasi yang berbeda dari model kecil.

28 Regularisasi pada CNN

Pada CNN, regularisasi meliputi data augmentation, weight decay, dropout, batch normalization, cutout, Mixup, dan CutMix. Data augmentation sangat penting karena citra memiliki invariansi alami terhadap transformasi tertentu. Jika label tidak berubah oleh transformasi T , maka idealnya

$$f_\theta(T(\mathbf{x})) \approx f_\theta(\mathbf{x}). \quad (68)$$

Regularisasi ini mendorong model belajar fitur yang tidak sensitif terhadap transformasi yang tidak relevan.

29 Regularisasi pada RNN

Pada RNN, regularisasi umum meliputi dropout, recurrent dropout, weight decay, gradient clipping, dan early stopping. Recurrent dropout harus diterapkan hati-hati karena mask yang berubah setiap waktu dapat merusak memori temporal. Salah satu strategi adalah menggunakan mask yang sama sepanjang waktu:

$$\tilde{\mathbf{h}}_t = \mathbf{m} \odot \mathbf{h}_t, \quad \mathbf{m} \text{ tetap untuk semua } t. \quad (69)$$

30 Flat Minima dan Regularisasi Implisit

Regularisasi tidak hanya berasal dari penalti eksplisit. Optimizer seperti SGD juga memiliki regularisasi implisit. Solusi yang ditemukan SGD sering berada pada daerah minimum yang relatif datar. Minimum datar berarti perubahan kecil pada parameter tidak banyak mengubah loss.

Secara intuitif, jika Hessian loss $\nabla^2 \mathcal{L}(\theta)$ memiliki eigenvalue kecil, maka loss berubah perlahan di sekitar solusi. Minimum yang datar sering diasosiasikan dengan generalisasi lebih baik. Ukuran lokalnya dapat dilihat dari aproksimasi Taylor:

$$\mathcal{L}(\theta + \Delta) \approx \mathcal{L}(\theta) + \nabla \mathcal{L}(\theta)^T \Delta + \frac{1}{2} \Delta^T \nabla^2 \mathcal{L}(\theta) \Delta. \quad (70)$$

Pada titik minimum, gradien mendekati nol, sehingga sensitivitas dipengaruhi oleh Hessian.

31 Contoh Perhitungan L2

Misalkan loss empiris sederhana adalah

$$\hat{R}(w) = (w - 4)^2. \quad (71)$$

Dengan regularisasi L2,

$$\mathcal{J}(w) = (w - 4)^2 + \lambda w^2. \quad (72)$$

Turunannya adalah

$$\frac{d\mathcal{J}}{dw} = 2(w - 4) + 2\lambda w. \quad (73)$$

Setarakan dengan nol:

$$(w - 4) + \lambda w = 0. \quad (74)$$

Maka solusi optimal adalah

$$w^* = \frac{4}{1 + \lambda}. \quad (75)$$

Jika $\lambda = 1$, maka

$$w^* = 2. \quad (76)$$

Tanpa regularisasi, solusi adalah $w = 4$. Dengan L2, bobot mengecil menuju nol.

32 Pemilihan Koefisien Regularisasi

Koefisien regularisasi λ harus dipilih dengan hati-hati. Jika terlalu kecil, regularisasi tidak cukup mencegah overfitting. Jika terlalu besar, model dapat underfitting. Nilai λ biasanya dipilih berdasarkan validasi, misalnya grid search:

$$\lambda \in \{10^{-5}, 10^{-4}, 10^{-3}, 10^{-2}, 10^{-1}\}. \quad (77)$$

Pilih λ yang meminimalkan loss validasi:

$$\lambda^* = \arg \min_{\lambda} \hat{R}_{val}(\theta_{\lambda}). \quad (78)$$

33 Kelebihan dan Keterbatasan Regularisasi

Kelebihan regularisasi meliputi:

- mengurangi overfitting,
- meningkatkan generalisasi,
- membuat model lebih robust terhadap noise,
- membantu stabilitas pelatihan,
- dapat mengurangi kompleksitas efektif model.

Keterbatasannya meliputi:

- regularisasi terlalu kuat dapat menyebabkan underfitting,
- membutuhkan tuning hiperparameter,
- beberapa teknik menambah biaya komputasi,
- tidak menggantikan kebutuhan data berkualitas,
- efek regularisasi dapat berbeda antar arsitektur dan dataset.

34 Perbandingan Teknik Regularisasi

Teknik	Ide Utama	Efek	Catatan
L2 / Weight decay	Penalti bobot kuadrat	Bobot kecil	Umum dipakai
L1	Penalti nilai absolut	Sparsity	Seleksi fitur
Dropout	Matikan neuron acak	Ensemble implisit	Populer di MLP
Data augmentation	Transformasi data	Invariansi	Sangat penting
Early stopping	Hentikan lebih awal	Cegah hafalan	Perlu validasi
Label smoothing	Label tidak ekstrem	Kurangi overconfidence	Klasifikasi
Mixup/CutMix	Campur sampel	Batas keputusan halus	Efektif pada citra

35 Kesimpulan

Regularization dalam deep learning adalah konsep penting untuk meningkatkan generalisasi dan mencegah overfitting. Secara matematis, regularisasi sering dinyatakan sebagai penalti tambahan pada fungsi objektif, seperti L1 dan L2. Namun, regularisasi juga dapat muncul melalui teknik pelatihan seperti dropout, data augmentation, label smoothing, Mixup, early stopping, gradient clipping, dan adversarial training.

Regularisasi dapat dipahami dari berbagai sudut pandang: pengendalian kompleksitas model, bias-variance tradeoff, prior Bayesian, robustness terhadap gangguan, dan regularisasi implisit dari optimizer. Tidak ada satu teknik regularisasi yang selalu terbaik. Pemilihan regularisasi bergantung pada arsitektur, ukuran dataset, tingkat noise, tujuan model, dan sumber daya komputasi. Dengan regularisasi yang tepat, model deep learning dapat belajar pola yang lebih umum, stabil, dan berguna pada data baru.