

Teori Transfer Learning dalam Deep Learning

Ryan Fadhilah Faizal Hakim¹

¹Sains Data, Fakultas Sains dan Teknologi, IKOPIN University

1 Pendahuluan

Transfer learning adalah paradigma pembelajaran mesin ketika pengetahuan yang diperoleh dari suatu tugas atau domain digunakan kembali untuk membantu pembelajaran pada tugas atau domain lain. Dalam *deep learning*, transfer learning sangat penting karena pelatihan model besar dari awal membutuhkan data, waktu, dan komputasi yang sangat besar. Dengan memanfaatkan model yang telah dilatih sebelumnya pada dataset besar, model dapat beradaptasi ke tugas baru dengan data yang lebih sedikit.

Secara intuitif, jaringan saraf dalam mempelajari representasi secara hierarkis. Pada visi komputer, lapisan awal sering mempelajari tepi, warna, dan tekstur; lapisan menengah mempelajari bagian objek; lapisan akhir mempelajari konsep yang lebih spesifik terhadap tugas. Pada pemrosesan bahasa alami, model pralatih dapat mempelajari struktur sintaksis, semantik, dan konteks. Transfer learning memanfaatkan representasi umum tersebut untuk mempercepat dan memperbaiki pembelajaran pada tugas target.

Jika pembelajaran biasa mengasumsikan data latih dan data uji berasal dari distribusi yang sama, transfer learning lebih fleksibel karena memperbolehkan adanya perbedaan antara domain sumber dan domain target. Tujuan utamanya adalah meningkatkan performa pada target menggunakan pengetahuan dari sumber.

2 Notasi Dasar

Sebuah domain didefinisikan sebagai pasangan

$$\mathcal{D} = \{\mathcal{X}, P(X)\}, \quad (1)$$

dengan $\mathcal{X}$ adalah ruang fitur dan $P(X)$ adalah distribusi marginal input. Sebuah tugas didefinisikan sebagai

$$\mathcal{T} = \{\mathcal{Y}, f(\cdot)\}, \quad (2)$$

dengan $\mathcal{Y}$ adalah ruang label dan $f(\cdot)$ adalah fungsi prediktif yang dipelajari dari data.

Transfer learning melibatkan domain sumber dan target:

$$\mathcal{D}_S = \{\mathcal{X}_S, P_S(X)\}, \quad (3)$$

$$\mathcal{T}_S = \{\mathcal{Y}_S, f_S(\cdot)\}, \quad (4)$$

$$\mathcal{D}_T = \{\mathcal{X}_T, P_T(X)\}, \quad (5)$$

$$\mathcal{T}_T = \{\mathcal{Y}_T, f_T(\cdot)\}. \quad (6)$$

Dataset sumber dan target dapat ditulis sebagai

$$\mathcal{S} = \{(\mathbf{x}_S^{(i)}, y_S^{(i)})\}_{i=1}^{n_S}, \quad (7)$$

$$\mathcal{T} = \{(\mathbf{x}_T^{(j)}, y_T^{(j)})\}_{j=1}^{n_T}. \quad (8)$$

Biasanya $n_S \gg n_T$, yaitu data sumber jauh lebih banyak daripada data target.

Secara umum, transfer learning bertujuan meningkatkan performa fungsi target f_T dengan memanfaatkan pengetahuan dari $\mathcal{D}_S$ dan $\mathcal{T}_S$, terutama ketika

$$\mathcal{D}_S \neq \mathcal{D}_T \quad \text{atau} \quad \mathcal{T}_S \neq \mathcal{T}_T. \quad (9)$$

3 Formulasi Risiko Empiris

Dalam pembelajaran terawasi biasa, model f_θ dilatih dengan meminimalkan risiko empiris pada data target:

$$\hat{R}_T(\theta) = \frac{1}{n_T} \sum_{j=1}^{n_T} \mathcal{L}(f_\theta(\mathbf{x}_T^{(j)}), y_T^{(j)}), \quad (10)$$

dengan $\mathcal{L}$ adalah fungsi loss. Risiko sebenarnya pada domain target adalah

$$R_T(\theta) = \mathbb{E}_{(\mathbf{x}, y) \sim P_T} [\mathcal{L}(f_\theta(\mathbf{x}), y)]. \quad (11)$$

Ketika n_T kecil, estimasi $\hat{R}_T(\theta)$ dapat memiliki varians tinggi sehingga model mudah overfitting. Transfer learning mengurangi masalah ini dengan menggunakan parameter atau representasi dari model sumber.

Jika model sumber memiliki parameter θ_S , maka pelatihan target dapat dimulai dari

$$\theta_0 = \theta_S, \quad (12)$$

bukan dari inisialisasi acak. Optimisasi target kemudian menjadi

$$\theta_T^* = \arg \min_{\theta} \hat{R}_T(\theta), \quad \theta \text{ diinisialisasi dari } \theta_S. \quad (13)$$

4 Motivasi Transfer Learning

Transfer learning digunakan karena beberapa alasan utama:

1. **Efisiensi data:** model target dapat dilatih dengan data lebih sedikit.
2. **Efisiensi komputasi:** pelatihan lebih cepat karena tidak dimulai dari nol.
3. **Generalization:** representasi pralatih sering lebih stabil dan lebih umum.
4. **Regularisasi implisit:** parameter pralatih membatasi ruang solusi ke wilayah yang lebih baik.
5. **Kinerja lebih tinggi:** model pralatih sering mengungguli model yang dilatih dari awal pada dataset kecil.

Secara matematis, manfaat transfer dapat dipandang sebagai pengurangan error generalisasi. Jika error target ditulis sebagai

$$R_T(\theta) - \hat{R}_T(\theta), \quad (14)$$

maka representasi pralatih dapat membantu memilih hipotesis dengan kompleksitas efektif lebih rendah, sehingga gap generalisasi dapat mengecil.

5 Jenis-Jenis Transfer Learning

Transfer learning dapat dibagi berdasarkan hubungan antara domain dan tugas.

5.1 Inductive Transfer Learning

Inductive transfer learning terjadi ketika tugas sumber dan target berbeda:

$$\mathcal{T}_S \neq \mathcal{T}_T. \quad (15)$$

Contohnya adalah menggunakan model CNN yang dilatih untuk klasifikasi ImageNet, lalu menyesuaikannya untuk klasifikasi penyakit pada citra medis. Label target tersedia, tetapi jumlahnya mungkin terbatas.

5.2 Transductive Transfer Learning

Transductive transfer learning terjadi ketika tugas sumber dan target sama, tetapi domain berbeda:

$$\mathcal{T}_S = \mathcal{T}_T, \quad \mathcal{D}_S \neq \mathcal{D}_T. \quad (16)$$

Contohnya adalah model sentimen yang dilatih pada ulasan film lalu diterapkan pada ulasan produk. Perbedaan distribusi input sering disebut domain shift.

5.3 Unsupervised Transfer Learning

Unsupervised transfer learning terjadi ketika tugas target tidak memiliki label. Tujuannya dapat berupa clustering, representasi, atau generasi data. Model belajar dari sumber dan menyesuaikan representasi pada target tanpa supervisi eksplisit.

6 Feature Extraction

Strategi transfer learning paling sederhana adalah menggunakan model pralatih sebagai ekstraktor fitur. Misalkan model pralatih dibagi menjadi dua bagian:

$$f_{\theta_S}(\mathbf{x}) = h_{\psi_S}(g_{\omega_S}(\mathbf{x})), \quad (17)$$

dengan g_{ω_S} sebagai feature extractor dan h_{ψ_S} sebagai classifier sumber. Pada target, parameter ω_S dibekukan, lalu classifier baru h_{ψ_T} dilatih:

$$\hat{y} = h_{\psi_T}(g_{\omega_S}(\mathbf{x})). \quad (18)$$

Objektif pelatihan menjadi

$$\psi_T^* = \arg \min_{\psi} \frac{1}{n_T} \sum_{j=1}^{n_T} \mathcal{L} \left(h_{\psi}(g_{\omega_S}(\mathbf{x}_T^{(j)})), y_T^{(j)} \right). \quad (19)$$

Karena ω_S tidak diperbarui, jumlah parameter yang dilatih lebih sedikit dan risiko overfitting berkurang.

7 Fine-Tuning

Fine-tuning adalah strategi ketika sebagian atau seluruh parameter model pralatih diperbarui menggunakan data target. Jika parameter model dibagi menjadi parameter feature extractor ω dan classifier ψ , maka optimisasi fine-tuning adalah

$$(\omega_T^*, \psi_T^*) = \arg \min_{\omega, \psi} \frac{1}{n_T} \sum_{j=1}^{n_T} \mathcal{L} \left(h_{\psi}(g_{\omega}(\mathbf{x}_T^{(j)})), y_T^{(j)} \right), \quad (20)$$

dengan inisialisasi

$$\omega_0 = \omega_S, \quad \psi_0 \text{ diinisialisasi ulang atau dari sumber.} \quad (21)$$

Fine-tuning dapat dilakukan dalam beberapa cara:

1. **Full fine-tuning**: semua lapisan diperbarui.
2. **Partial fine-tuning**: hanya lapisan atas yang diperbarui.

3. **Linear probing:** backbone dibekukan dan hanya classifier linear dilatih.
4. **Gradual unfreezing:** lapisan dibuka secara bertahap dari atas ke bawah.

Pembaruan parameter pada gradient descent adalah

$$\theta_{t+1} = \theta_t - \eta \nabla_{\theta} \hat{R}_T(\theta_t). \quad (22)$$

Dalam fine-tuning, learning rate sering dibuat lebih kecil daripada training dari awal agar pengetahuan pralatih tidak rusak:

$$\eta_{fine} \ll \eta_{scratch}. \quad (23)$$

8 Layer-Wise Learning Rate

Dalam deep learning, lapisan awal sering mempelajari fitur umum, sedangkan lapisan akhir lebih spesifik terhadap tugas. Karena itu, fine-tuning sering menggunakan learning rate berbeda untuk setiap lapisan. Misalkan parameter lapisan ke- ℓ adalah $\theta^{(\ell)}$, maka

$$\theta_{t+1}^{(\ell)} = \theta_t^{(\ell)} - \eta_{\ell} \nabla_{\theta^{(\ell)}} \hat{R}_T(\theta_t). \quad (24)$$

Learning rate dapat dibuat meningkat ke arah lapisan akhir:

$$\eta_1 < \eta_2 < \dots < \eta_L. \quad (25)$$

Strategi ini menjaga fitur umum pada lapisan awal tetap stabil, sambil memungkinkan lapisan akhir beradaptasi lebih kuat terhadap tugas target.

9 Regularisasi terhadap Parameter Sumber

Transfer learning dapat diformulasikan sebagai regularisasi agar parameter target tidak terlalu jauh dari parameter sumber. Objektifnya adalah

$$\mathcal{J}(\theta) = \hat{R}_T(\theta) + \lambda \|\theta - \theta_S\|_2^2. \quad (26)$$

Term kedua mendorong model target tetap dekat dengan model sumber. Gradiennya adalah

$$\nabla_{\theta} \mathcal{J}(\theta) = \nabla_{\theta} \hat{R}_T(\theta) + 2\lambda(\theta - \theta_S). \quad (27)$$

Jika λ besar, model target sangat bergantung pada pengetahuan sumber. Jika λ kecil, model lebih bebas beradaptasi pada target.

10 Multi-Task Learning sebagai Transfer

Multi-task learning berkaitan erat dengan transfer learning. Beberapa tugas dilatih bersama dengan parameter bersama. Misalkan terdapat K tugas dengan loss $\mathcal{L}_1, \dots, \mathcal{L}_K$. Objektif total adalah

$$\mathcal{J}(\theta, \psi_1, \dots, \psi_K) = \sum_{k=1}^K \alpha_k \mathcal{L}_k(\theta, \psi_k), \quad (28)$$

dengan θ adalah parameter bersama dan ψ_k adalah parameter khusus tugas ke- k . Parameter bersama belajar representasi yang berguna bagi banyak tugas, sehingga dapat ditransfer ke tugas baru.

11 Domain Adaptation

Domain adaptation adalah bentuk transfer learning ketika distribusi sumber dan target berbeda. Misalkan

$$P_S(X, Y) \neq P_T(X, Y). \quad (29)$$

Perbedaan ini dapat muncul sebagai covariate shift, label shift, atau concept shift.

11.1 Covariate Shift

Covariate shift terjadi ketika distribusi input berubah tetapi fungsi label tetap sama:

$$P_S(X) \neq P_T(X), \quad P_S(Y|X) = P_T(Y|X). \quad (30)$$

Risiko target dapat ditulis menggunakan importance weighting:

$$R_T(\theta) = \mathbb{E}_{(\mathbf{x}, y) \sim P_S} \left[\frac{p_T(\mathbf{x})}{p_S(\mathbf{x})} \mathcal{L}(f_\theta(\mathbf{x}), y) \right]. \quad (31)$$

Bobot

$$w(\mathbf{x}) = \frac{p_T(\mathbf{x})}{p_S(\mathbf{x})} \quad (32)$$

memberi penekanan lebih besar pada sampel sumber yang mirip dengan distribusi target.

11.2 Label Shift

Label shift terjadi ketika distribusi label berubah tetapi distribusi input kondisional terhadap label tetap sama:

$$P_S(Y) \neq P_T(Y), \quad P_S(X|Y) = P_T(X|Y). \quad (33)$$

Kasus ini sering muncul ketika proporsi kelas pada target berbeda dari sumber.

11.3 Concept Shift

Concept shift terjadi ketika hubungan antara input dan label berubah:

$$P_S(Y|X) \neq P_T(Y|X). \quad (34)$$

Ini lebih sulit karena fungsi prediktif yang dipelajari pada sumber mungkin tidak lagi sesuai untuk target.

12 Adversarial Domain Adaptation

Salah satu pendekatan domain adaptation adalah membuat representasi yang tidak dapat membedakan domain. Misalkan feature extractor g_ω , classifier label h_ψ , dan domain discriminator d_ϕ . Label domain r bernilai 0 untuk sumber dan 1 untuk target.

Loss klasifikasi pada data sumber adalah

$$\mathcal{L}_{cls} = \frac{1}{n_S} \sum_{i=1}^{n_S} \mathcal{L} \left(h_\psi(g_\omega(\mathbf{x}_S^{(i)})), y_S^{(i)} \right). \quad (35)$$

Loss domain adalah

$$\mathcal{L}_{dom} = -\frac{1}{n_S + n_T} \sum_i [r_i \log d_\phi(g_\omega(\mathbf{x}_i)) + (1 - r_i) \log(1 - d_\phi(g_\omega(\mathbf{x}_i)))] . \quad (36)$$

Domain discriminator meminimalkan $\mathcal{L}_{dom}$, sedangkan feature extractor dilatih untuk memaksimalkan loss domain agar representasi domain-invariant. Objektif adversarial dapat ditulis sebagai

$$\min_{\omega, \psi} \max_{\phi} \mathcal{L}_{cls} - \lambda \mathcal{L}_{dom}. \quad (37)$$

Dengan demikian, fitur tetap informatif untuk label tetapi sulit digunakan untuk menebak domain.

13 Maximum Mean Discrepancy

Maximum Mean Discrepancy (MMD) adalah ukuran jarak antara dua distribusi dalam ruang reproducing kernel Hilbert space. Untuk representasi sumber dan target, MMD didefinisikan sebagai

$$\text{MMD}^2(P_S, P_T) = \|\mathbb{E}_{\mathbf{x} \sim P_S}[\varphi(\mathbf{x})] - \mathbb{E}_{\mathbf{x} \sim P_T}[\varphi(\mathbf{x})]\|_{\mathcal{H}}^2, \quad (38)$$

dengan φ adalah pemetaan fitur kernel. Estimator empirisnya adalah

$$\widehat{\text{MMD}}^2 = \frac{1}{n_S^2} \sum_{i,j} k(\mathbf{x}_S^{(i)}, \mathbf{x}_S^{(j)}) + \frac{1}{n_T^2} \sum_{i,j} k(\mathbf{x}_T^{(i)}, \mathbf{x}_T^{(j)}) - \frac{2}{n_S n_T} \sum_{i,j} k(\mathbf{x}_S^{(i)}, \mathbf{x}_T^{(j)}). \quad (39)$$

Dalam transfer learning, MMD dapat ditambahkan ke loss:

$$\mathcal{J} = \mathcal{L}_{cls} + \lambda \text{MMD}^2(P_S^g, P_T^g), \quad (40)$$

dengan P_S^g dan P_T^g adalah distribusi representasi sumber dan target setelah feature extractor.

14 Self-Supervised Pretraining

Self-supervised learning adalah pendekatan penting dalam transfer learning modern. Model dilatih pada tugas pralatih yang labelnya dibuat otomatis dari data. Setelah itu, model dipindahkan ke tugas target.

Misalkan tugas pralatih memiliki loss

$$\mathcal{L}_{pre}(\theta) = \frac{1}{N} \sum_{i=1}^N \ell_{pre}(f_{\theta}(\tilde{\mathbf{x}}^{(i)}), s(\mathbf{x}^{(i)})), \quad (41)$$

dengan $s(\mathbf{x})$ adalah sinyal supervisi otomatis. Parameter pralatih diperoleh dari

$$\theta_{pre} = \arg \min_{\theta} \mathcal{L}_{pre}(\theta). \quad (42)$$

Kemudian model diadaptasi pada target:

$$\theta_T = \arg \min_{\theta} \mathcal{L}_{target}(\theta), \quad \theta_0 = \theta_{pre}. \quad (43)$$

Contoh self-supervised pretraining adalah masked language modeling, contrastive learning, image reconstruction, rotation prediction, dan next sentence prediction.

15 Contrastive Learning untuk Transfer

Contrastive learning melatih representasi agar sampel positif saling dekat dan sampel negatif saling jauh. Misalkan $\mathbf{z}_i$ dan $\mathbf{z}_j$ adalah dua augmentasi dari data yang sama, sedangkan $\mathbf{z}_k$ adalah sampel negatif. Loss InfoNCE dapat ditulis sebagai

$$\mathcal{L}_{i,j} = -\log \frac{\exp(\text{sim}(\mathbf{z}_i, \mathbf{z}_j)/\tau)}{\sum_{k=1}^{2N} \mathbb{I}_{k \neq i} \exp(\text{sim}(\mathbf{z}_i, \mathbf{z}_k)/\tau)}, \quad (44)$$

dengan $\text{sim}(\cdot, \cdot)$ adalah cosine similarity dan τ adalah temperature. Representasi yang dipelajari melalui contrastive learning sering dapat ditransfer ke banyak tugas downstream.

16 Transfer Learning pada Visi Komputer

Pada visi komputer, transfer learning sering menggunakan CNN atau vision transformer pralatih. Misalkan backbone menghasilkan representasi

$$\mathbf{h} = g_{\omega}(\mathbf{x}). \quad (45)$$

Untuk klasifikasi target dengan K kelas, classifier baru adalah

$$\hat{\mathbf{y}} = \text{softmax}(\mathbf{W}\mathbf{h} + \mathbf{b}). \quad (46)$$

Loss target adalah cross-entropy:

$$\mathcal{L}_{CE} = - \sum_{k=1}^K y_k \log \hat{y}_k. \quad (47)$$

Jika dataset target kecil dan mirip dengan dataset sumber, feature extraction atau partial fine-tuning biasanya cukup. Jika dataset target besar atau berbeda jauh, full fine-tuning lebih sesuai.

17 Transfer Learning pada Pemrosesan Bahasa Alami

Dalam pemrosesan bahasa alami, transfer learning banyak dilakukan melalui model bahasa pralatih. Model dilatih untuk memaksimalkan probabilitas token berdasarkan konteks. Untuk language modeling autoregressive,

$$p(\mathbf{x}) = \prod_{t=1}^T p(x_t | x_1, \dots, x_{t-1}). \quad (48)$$

Loss pralatihnya adalah negative log-likelihood:

$$\mathcal{L}_{LM} = - \sum_{t=1}^T \log p_{\theta}(x_t | x_{<t}). \quad (49)$$

Untuk masked language modeling, sebagian token disembunyikan dan model memprediksi token tersebut:

$$\mathcal{L}_{MLM} = - \sum_{t \in \mathcal{M}} \log p_{\theta}(x_t | \mathbf{x}_{\setminus \mathcal{M}}), \quad (50)$$

dengan $\mathcal{M}$ adalah indeks token yang dimask. Setelah pralatih, model dapat di-fine-tune untuk klasifikasi teks, ekstraksi informasi, tanya jawab, atau generasi teks.

18 Parameter-Efficient Fine-Tuning

Untuk model besar, full fine-tuning membutuhkan memori dan komputasi besar. Parameter-efficient fine-tuning hanya melatih sebagian kecil parameter tambahan.

18.1 Adapter

Adapter menambahkan modul kecil pada setiap lapisan. Jika aktivasi lapisan adalah $\mathbf{h}$, adapter dapat ditulis sebagai

$$\text{Adapter}(\mathbf{h}) = \mathbf{h} + \mathbf{W}_{up} \sigma(\mathbf{W}_{down} \mathbf{h}), \quad (51)$$

dengan $\mathbf{W}_{down}$ menurunkan dimensi dan $\mathbf{W}_{up}$ mengembalikan dimensi. Parameter backbone dibekukan, hanya adapter yang dilatih.

18.2 Low-Rank Adaptation

Low-Rank Adaptation (LoRA) mengadaptasi matriks bobot dengan pembaruan berperingkat rendah. Jika bobot asli adalah $\mathbf{W}_0$, maka bobot teradaptasi adalah

$$\mathbf{W} = \mathbf{W}_0 + \Delta\mathbf{W}, \quad \Delta\mathbf{W} = \mathbf{B}\mathbf{A}, \quad (52)$$

dengan $\mathbf{A} \in \mathbb{R}^{r \times d}$, $\mathbf{B} \in \mathbb{R}^{k \times r}$, dan $r \ll \min(d, k)$. Selama pelatihan, $\mathbf{W}_0$ dibekukan, sedangkan $\mathbf{A}$ dan $\mathbf{B}$ diperbarui.

Jumlah parameter tambahan LoRA adalah

$$r(d + k), \quad (53)$$

yang jauh lebih kecil dibanding melatih seluruh matriks $\mathbf{W}_0 \in \mathbb{R}^{k \times d}$ dengan kd parameter.

19 Negative Transfer

Negative transfer terjadi ketika pengetahuan dari sumber justru menurunkan performa pada target. Hal ini dapat terjadi jika domain atau tugas sumber terlalu berbeda dari target. Secara konseptual, transfer bermanfaat jika

$$R_T(\theta_{transfer}) < R_T(\theta_{scratch}), \quad (54)$$

dan menjadi negative transfer jika

$$R_T(\theta_{transfer}) > R_T(\theta_{scratch}). \quad (55)$$

Penyebab negative transfer meliputi:

- perbedaan distribusi input yang besar,
- perbedaan label atau definisi kelas,
- fitur sumber terlalu spesifik,
- fine-tuning dengan learning rate tidak tepat,
- dataset target mengandung pola yang bertentangan dengan sumber.

20 Catastrophic Forgetting

Catastrophic forgetting terjadi ketika model yang di-fine-tune pada target kehilangan kemampuan pada tugas sumber. Jika performa sumber sebelum fine-tuning adalah $A_S(\theta_S)$ dan setelah fine-tuning menjadi $A_S(\theta_T)$, forgetting dapat diukur sebagai

$$F = A_S(\theta_S) - A_S(\theta_T). \quad (56)$$

Semakin besar F , semakin banyak pengetahuan sumber yang hilang.

Salah satu pendekatan untuk mengurangi forgetting adalah regularisasi Fisher seperti Elastic Weight Consolidation. Objektifnya adalah

$$\mathcal{J}(\theta) = \mathcal{L}_T(\theta) + \frac{\lambda}{2} \sum_i F_i(\theta_i - \theta_{S,i})^2, \quad (57)$$

dengan F_i mengukur pentingnya parameter ke- i untuk tugas sumber.

21 Strategi Praktis Pemilihan Metode

Pemilihan strategi transfer learning bergantung pada ukuran dataset target dan kemiripan domain:

1. Jika dataset target kecil dan mirip sumber, gunakan feature extraction atau linear probing.
2. Jika dataset target sedang dan mirip sumber, gunakan partial fine-tuning.
3. Jika dataset target besar, gunakan full fine-tuning.
4. Jika domain target sangat berbeda, pertimbangkan domain adaptation atau pretraining tambahan.
5. Jika model sangat besar, gunakan parameter-efficient fine-tuning seperti adapter atau LoRA.

Secara umum, validasi target harus digunakan untuk memilih learning rate, jumlah lapisan yang dibuka, regularisasi, dan jumlah epoch.

22 Evaluasi Transfer Learning

Efektivitas transfer learning dapat diukur dengan membandingkan model transfer terhadap baseline dari awal. Transfer gain dapat didefinisikan sebagai

$$G = M(\theta_{transfer}) - M(\theta_{scratch}), \quad (58)$$

dengan M adalah metrik performa seperti akurasi, F1-score, atau AUC. Jika $G > 0$, transfer learning memberikan manfaat.

Efisiensi data dapat dianalisis dengan membandingkan performa pada berbagai ukuran data target:

$$M_k = M(\theta; n_T = k). \quad (59)$$

Model transfer yang baik biasanya mencapai performa tinggi pada k yang lebih kecil dibanding model yang dilatih dari awal.

23 Contoh Perhitungan Sederhana

Misalkan model pralatih memiliki parameter sumber $\theta_S = 2.0$ untuk kasus satu dimensi. Pada target, loss empiris sederhana adalah

$$\hat{R}_T(\theta) = (\theta - 3)^2. \quad (60)$$

Jika digunakan regularisasi terhadap parameter sumber,

$$\mathcal{J}(\theta) = (\theta - 3)^2 + \lambda(\theta - 2)^2. \quad (61)$$

Turunan objektif adalah

$$\frac{d\mathcal{J}}{d\theta} = 2(\theta - 3) + 2\lambda(\theta - 2). \quad (62)$$

Dengan menyamakan turunan ke nol,

$$(\theta - 3) + \lambda(\theta - 2) = 0. \quad (63)$$

Maka solusi optimal adalah

$$\theta^* = \frac{3 + 2\lambda}{1 + \lambda}. \quad (64)$$

Jika $\lambda = 1$, maka

$$\theta^* = \frac{5}{2} = 2.5. \quad (65)$$

Solusi ini berada di antara optimum target 3 dan parameter sumber 2, menunjukkan kompromi antara adaptasi target dan retensi pengetahuan sumber.

24 Kelebihan dan Keterbatasan Transfer Learning

Kelebihan transfer learning meliputi:

- mengurangi kebutuhan data target,
- mempercepat konvergensi pelatihan,
- meningkatkan performa pada dataset kecil,
- memanfaatkan representasi umum dari dataset besar,
- memungkinkan penggunaan model besar pada banyak tugas downstream.

Keterbatasannya meliputi:

- dapat menyebabkan negative transfer jika sumber tidak relevan,
- fine-tuning dapat menghapus pengetahuan lama,
- membutuhkan pemilihan learning rate dan strategi freezing yang hati-hati,
- model pralatih dapat membawa bias dari dataset sumber,
- model besar dapat mahal untuk disimpan dan diadaptasi.

25 Perbandingan Strategi Transfer Learning

Strategi	Parameter Dilatih	Kelebihan	Risiko
Feature extraction	Classifier baru	Cepat dan stabil	Kurang adaptif
Linear probing	Head linear	Evaluasi representasi mudah	Terbatas pada fitur tetap
Partial fine-tuning	Lapisan atas	Adaptif dan cukup stabil	Pemilihan lapisan
Full fine-tuning	Semua parameter	Performa tinggi	Overfitting dan forgetting
Adapter/LoRA	Parameter kecil tambahan	Hemat memori	Adaptasi terbatas
Domain adaptation	Extractor dan alignment	Mengatasi domain shift	Training lebih kompleks

26 Aplikasi Transfer Learning

Transfer learning digunakan dalam berbagai bidang:

1. **Visi komputer:** klasifikasi citra, deteksi objek, segmentasi, dan pengenalan wajah.
2. **Citra medis:** diagnosis penyakit dari X-ray, MRI, CT scan, dan histopatologi.
3. **Pemrosesan bahasa alami:** klasifikasi teks, tanya jawab, ringkasan, dan penerjemahan.
4. **Audio:** pengenalan ucapan, klasifikasi suara, dan deteksi anomali audio.
5. **Robotika:** transfer kebijakan dari simulasi ke dunia nyata.
6. **Rekomendasi:** adaptasi model dari satu domain pengguna ke domain lain.
7. **Remote sensing:** klasifikasi lahan dan deteksi objek dari citra satelit.

27 Kesimpulan

Transfer learning adalah pendekatan penting dalam deep learning yang memanfaatkan pengetahuan dari domain atau tugas sumber untuk meningkatkan pembelajaran pada domain atau tugas target. Secara matematis, transfer learning dapat dipahami melalui inisialisasi parameter, ekstraksi fitur, fine-tuning, regularisasi terhadap parameter sumber, domain adaptation, dan alignment distribusi.

Keberhasilan transfer learning bergantung pada relevansi antara sumber dan target, jumlah data target, strategi fine-tuning, regularisasi, dan pemilihan hiperparameter. Metode modern seperti self-supervised pretraining, contrastive learning, adapter, dan LoRA membuat model besar dapat diadaptasi secara efisien. Meskipun sangat bermanfaat, transfer learning tetap perlu digunakan dengan hati-hati karena risiko negative transfer, bias sumber, dan catastrophic forgetting.